

例示は想起を動かし、指示は棄却を動かす： Closed-book 知識ベース構築における推論時介入の解剖

Takashi Sasaki
Acroquest Technology Co., Ltd.
takashi.ssk1029@gmail.com

Abstract

本稿では、AKBC 2026 closed-book 知識ベース構築共有タスクへの提出システムを報告する。最終システムは、Mistral Small 3.2(24B) から意図的に様式の異なる 2 種類のプロンプトでクエリごとに 20 候補をサンプリングし、関係ごとの方策で集約した上で、2 つのプロンプトの答えが食い違う行だけを系列の異なる 8B モデル (Llama-3.1-8B) の一票で裁定する。総パラメータ数はタスク上限 32B に対して 31.8B である。検証セットで Macro F1 0.641、公式テストセットで 0.625 を達成した (公式ベースラインは 0.313)。本稿の大部分は、2 つの基盤モデルと約 25 本の統制実験にまたがる仕組みの解明に充て、「closed-book システムを実際に動かす推論時介入はどれで、動かしたように見えるだけの介入はどれか」を問う。知見は以下である: (1) 実体名から値を正しく思い出せるかどうか (想起の確かさ) が、試したすべての介入を支配する。12 行の想起診断が 10 モデルにわたりシステム品質を予測し、モデルの変更は 9 本の介入実験の合計よりスコアを動かした。(2) 候補内部の想起は単発の早期アンカーサンプリングであり、その分布を動かすのは指示文ではなく**例示の様式**である。一文の言語化想起を実演する 2 件の in-prompt 例示は回答モードを +6 行動かすが、同じ内容を指示として与えても、素の JSON の few-shot 例示の下では何も動かない。(3) この効果は条件付きである。想起の弱いモデルでは効果がなく、想起の弱い関係では有害であり、RL 後訓練は完全にこれを切断する。(4) 単一モデルの候補集合内での選択には使える情報がないが、2 つのプロンプトが食い違う行を系列外の 8B モデルで裁定する設計は、検証と公式テストの両方で行数を稼ぎ、隔離されたアブレーションがテストでの再現を確認した。(5) 検証上の利得は、テストでも再現するもの (仕組みで説明できるもの: 例示様式・集計上の不具合の修正・行数を減らさない裁定) と再現しないもの (検証行の統計への適合) に綺麗に分かれ、100 行の検証セットはその違いを検出できない。

1 はじめに

LM-KBC 共有タスク系列 (LM-KBC organizers, 2023, 2024) は、言語モデルの事実知識をどこまで知識ベースのエントリに変換できるかを問う。主語と関係が与えられ、システムは**すべての正しい目的語** (0 個、1 個、あるいは数百個) を closed-book 条件下で出力する: 検索なし・外部コーパスなし・fine-tuning なし・推論時の総パラメータ数 32B 以下。

この条件下で使える手段は推論時のものに限られる: モデル選択・プロンプト・サンプリング・サンプル上の集約である。我々は実質的に 2 度参加した。まず Qwen3.5-27B の thinking システム (test 0.571) で、次に体系的モデルスクリーニングを経た Mistral Small 3.2 システム (最終形は第 2 のプロンプトと系列外の 8B 裁定者を加え、test 0.610) である。システムと並行して、各決定を導いた統制実験を報告する。7 回の提出はそれぞれ公式テストスコアを持ち、検証では得られないもの——隠しセット上での隔離アブレーションと、利得がテストでも再現するかの測定——を与える。浮かび上がる構図は次の通りである:

1. **想起の確かさが支配する**。12 行の診断 (1 モデルあたり GPU 30 分) は 10 モデルにわたり下流品質を予測し、Qwen から Mistral への変更は、プロンプト・サンプリング・選択の全実験の合計を上回った (4.1 節)。
2. **想起は単発の早期アンカーサンプリングである** (4.2 節)。系列を跨いで再現する。
3. **例示様式はアンカー分布を動かし、指示文は動かさない** (4.3 節)——想起の確かさと後訓練に条件付きで (4.4 節)。
4. **単一モデル内の選択には使える情報がないが、プロンプト間・系列間では違う** (4.5 節)。
5. **検証上の利得はテストで再現する型としない型に分かれ、その分かれ目は効果量ではなく仕組みである** (4.6 節)。

6. 残る誤りは学習コーパス由来の誤った値である: モデル内では安定し、世代ごとに入れ替わり、系列間で共有され、instruct チューニングにより増幅される (4.7 節)。

2 タスクと制約

2026 年版タスクは、478 検証行・477 テスト行の 6 関係を対象とする: 空集合がありうる 2 つの集合値関係 (countryLandBordersCountry, companyTradesAtStockExchange)、空がありうる単一値文字列関係 (personHasCityOfDeath)、大集合関係 (awardWonBy)、5% 相対許容誤差で採点される 2 つの数値関係 (hasArea, hasCapacity)。gold は Wikidata に由来し (面積は P2046、収容人数は P1083)、文字列回答には別名リストが許容される。公式の「All Relations」スコアは関係ではなく行の平均であり、100 行の 4 関係が支配的である。システムは closed-book で、推論時パラメータ総数は量子化に関わらず 32B が上限である。

3 システム記述

3.1 生成

最終システムは Mistral Small 3.2 24B (BF16 GGUF—公開重みの無損失再梱包) を llama.cpp でリビジョン固定して提供し、クエリごとに 20 候補、温度 0.6、top- p 0.95、決定的な候補別シード、extended thinking なし (このモデルで thinking が無効果である理由は 4.4 節) で生成する。数値関係は意図的に様式の異なる 2 種類のプロンプトを使う:

想起プロンプト (hasArea): few-shot 例なし。代わりに関係指示が、ラベル付きの想起書式を実演する 2 件の in-prompt 例示を運ぶ (Entity: 指示対象を同定する一文; Memory: “I recall that the Wikipedia infobox lists X’s total area as Y”; Unit: 単位確認; Answer: 素の JSON 配列)。4.3 節が、有効成分は指示ではなく例示であることを示す。

出所指定プロンプト (hasArea, hasCapacity): 標準的な few-shot 例 5 件に加え、想起先を名指す指示 (「gold は Wikidata プロパティ P2046/P1083 の格納値であり、Wikipedia infobox に表示される、正確にこの名前を持つ実体の値である」)。capacity には桁保持と曖昧性解消の句を加える。文字列関係は素のタスクプロンプト+few-shot 5 件を使う。hasCapacity には追加パラメータゼロの第 3 のプロンプトを加える: 同一の 24B モデルを素の続き書き形式 (Wikipedia infobox 風の接頭辞を、チャットテンプレートを使わずに継続生成させる) で照会

したもので、チャット形式では出ない正確な格納値を供給する (4.7 節)。

3.2 集約と裁定

数値候補は 5% 相対許容誤差でクラスタし、dominant_cluster は最大支持クラスタの中央値を予測する。unit_equivalence は単位換算係数で関係づくクラスタを先に併合する。personHasCityOfDeath は多数決を用い、最小得票に満たない場合は無回答とする。companyTradesAtStockExchange は頻度しきい値 (0.5) を用い、空回答が多数なら無回答とするが、その前に表記ゆれ—大文字小文字の変種と、共起する長い形の頭文字を綴る略語 (NYSE → New York Stock Exchange)—を単一のカウントに統合する。これにより、多数派回答が票割れでしきい値を下回る事故が修復される。awardWonBy は再現率志向のしきい値と、Qwen 時代のシステムから引き継いだ全会一致 no 検証フィルタを維持する。

系列間の裁定。各数値行について 2 つのプロンプトは 2 つの集約回答を出す。両者が 5% を超えて食い違ふとき、第三の系列の異なるモデル—単独では遥かに弱い Llama-3.1-8B (表 2)—の 20 サンプルのモード値を尋ね、裁定者が副回答と一致しかつ主回答と一致しない場合に限り副回答へ切り替える。それ以外は主回答を維持する。この設計は構造上、行数を減らさない: どちらの選択肢も強いモデルの回答であり、一致しなければ既定値に留まる。総パラメータ: $24B + 8B \approx 31.8B \leq 32B$ 。

許容誤差の幾何を使ったブリッジ。最後に、各 hasArea 回答 v を自身の $\pm 5\%$ 窓内で動かし、両プロンプトの候補クラスタ区間を最も多くの票質量で被覆する点に置く。比が $1.05/0.95 \approx 1.105$ 未満の 2 値には両方に正解となる 1 点が存在するため、ブリッジはモードを手放さずに次点クラスタを被覆できる—どの少数派値が正しいかを識別する信号なしに、候補集合で達成しうる上限へ近づく方法である (4.5 節)。評価尺度の幾何から導出され、調整定数はなく、試したすべてのプロンプト対・裁定者シードで +1~+2 行を得た (80 を基準に 82/81/83/82)。

3.3 結果

表 1 がシステムの推移を示す。Qwen→Mistral の変更は他を変えないまま test +0.024 に相当し、Mistral 時代の介入とデータセット追従がさらに test +0.030 を加える。そのうちテストでも再現した成分はすべて仕組みで説明できるものである (4.6 節)。v8 時点の関係別テストスコアは: borders 0.958、area 0.800、company

システム	val	test
ベースライン (Qwen3.5-9B)	0.313	—
Qwen3.5-27B thinking 版	0.588	0.571
Mistral 3.2, 出所指定のみ	0.595	0.595
v3: + 想起プロンプト・ area 裁定・company 統合	0.629	0.604
v4: + capacity 裁定	0.633	0.606
v5: + 略語の統合	0.635	0.610
v6: + capacity 第 2 裁定者 [†]	0.637	0.610
v7: + city 統合 (棄却)	0.660	0.608
v8: データ改訂に追従 [*]	0.637	0.625
v9-v10: + area ブリッジ; 準拠版で [†] を置換	0.641	測定待ち

Table 1: システムの推移 (Macro F1)。各 v_n は直前の版と既知の少数行のみが異なるため、テスト列は隠しセット上の隔離アブレーションの系列を兼ねる (4.6 節)。*8 月の主語曖昧性解消リリースがテスト主語 15 件を改名し 2 行を削除した (477→475)。v7 までの提出は改名行を 0 点として採点されるため、約 0.015 過小評価されている。[†]32B 上限を超過させた第 2 の 8B 裁定者。v10 は検証スコア同値のまま追加パラメータゼロの続き書きプロンプトで置換した (Limitations 参照)。

0.778、city 0.510、award 0.279、capacity 0.214。

4 推論時介入の解剖

すべての実験は明示した 1 つの条件のみを変更する。数値系のテストベッドは hasArea と hasCapacity(検証 100 行 × プロンプトごと 20 候補)である。**候補内正解**は候補集合のどこかに許容誤差内の値がある行数、**最頻値正解**は dominant_cluster が選んで正解となる行数。**アンカー**は候補内で問われた量に対して最初に現れる具体値である。

4.1 想起の確かさが支配する: 12 行の診断による測定

Qwen 時代のシステムは 9 本の介入実験 (プロンプト・温度・出力経路・思考長・判定モデル・対数尤度による信頼度) の後に頭打ちとなり、展開可能な合計利得は +0.01 未満だった。そのシステムの誤答行 12 行の診断を候補モデル横断で実行すると (表 2)、Mistral Small 3.2 は 12 行中 11 行を候補集合のどこかで正答した。他を変えずに Mistral で全パイプラインを再生成すると、検証 0.588→0.595、テスト 0.571→0.595—それまでに試したすべての合計を上回った。我々はこれをタスクの第一次的事実とみなす: closed-book KBC の品質は、モデルの事前学習がラベルと値の対応をどれだけ正しく残したかで決まり、30 分の診断がチューニング前にそれを測定する。

モデル (12 行診断)	正解あり	最頻値
Mistral Small 3.2 Instruct	11	8
Mistral Small 3.1 Base	10	7
Mistral Small 3.1 Instruct	9	4
Llama-3.1-8B Instruct	7	4
Aya Expanse 32B	3	1
Qwen3-8B	1	0

Table 2: 想起の診断: Qwen 時代システムの失敗を層化した 12 の hasArea 行、各 20 候補。**正解あり** = 正解候補が 1 つでもある行数、**最頻値** = 最頻クラスタが正解の行数。Qwen3.5/3.6-27B、Gemma 4 31B、GLM-Z1-32B、llm-jp-4-32b(表外) はいずれも Llama-8B と Aya の間に位置する。診断は 1 モデル GPU 約 30 分で、その順位は展開判断のすべてで全検証品質と一致した。

hasArea プロンプト (Mistral 3.2)	few-shot 例 素の JSON ×5	なし
出所指定の指示	71 (89)	41 (59)
想起書式の指示	72 (83)	78 (84–89)

Table 3: 2×2 の比較: 最頻値正解の行数 (括弧内は候補内正解)。想起書式の指示は想起の手順を実演する例示 2 件を内部に含むため、右下にはこの 2 件が残り、右上は例示が**皆無**で 41 に崩壊する。例示様式を固定すると指示文は ±1 しか動かさず、例示様式を変えると +6 / −30 動く。

4.2 想起は単発の早期アンカーサンプリングである

Qwen 時代システムの推論トレースを保存して測定すると、回答値はトレースの中央値 17% 地点で最初に出現し、95–98% の候補で想起テンプレート (“Commonly cited: X”) の中に現れる。残り 80% のトレースがそれを覆すことはない。検証テキストはアンカーを検証するのではなくアンカーに条件付けられる: 捏造された Wikidata Q-ID や多言語「照合」はアンカーが何であれそれに一致し、誤答候補は正解候補より**多く**のこの装置を伴う (ソース言及 6.9 vs. 4.2)。アンカーの機構は Gemma 4 31B と Qwen3.6 でも再現するが、検証文を捏造する様式は再現しない (Qwen の学習された文体である)。この描像の下で extended thinking は**探索**の補助である: 想起の弱いモデルでは候補内正解を引き上げ (Qwen +9 行、Gemma +7)、既に正しく想起できている Mistral とその RL 版 Magistral では効果がない。

4.3 例示様式は想起を動かし、指示文は動かさない

我々が発見した最大のプロンプト効果—hasArea の最頻値正解 72 → 78、テストへ

0.70 → 0.75 として再現——は、最初は指示の効果に見えた：他参加者が公開したステップ構造の専門家プロンプト（後に独自の文面で再導出）が出所指定の指示を 6 行上回ったのである。2×2 の比較（表 3）は、指示文がほぼ不活性であることを示す。効いているのは**例示**である：一文の言語化想起（“I recall that the Wikipedia infobox lists Luxembourg’s total area as 2586.4 km²”）を実演する 2 件の in-prompt 例示の下では候補の 99% が言語化を再現し、最頻値正解が +6 動く。従来型の素の JSON few-shot 例示 5 件の下では 0% しか言語化せず——同じ手順を指示文として与えても黙って無視される——最頻値正解は動かない。例示が皆無なら出力は崩壊する（41）。文面の反復（人格・定型句・出所語彙）は何も変えず、ラベル付きの構造を独自のラベルで再現すると効果は完全に回復した（78、候補内正解も最高の 89）。例示様式は指示文を支配する：例示は出力形式だけでなく想起分布の焦点そのものを規定する。利得はシードに対して安定である（78 ± 1、入れ替わりは 1 行）。

4.4 効果は条件付きである：想起の確かさと後訓練

言語化想起は**焦点化型**の介入であり、最も多く想起される値の周りにアンカー分布を鋭くする（最頻値正解の改善と引き換えに候補内正解は 89 → 84 に低下）。したがってその符号は、thinking と鏡像をなして想起の確かさに従う：thinking は探索であり、想起の弱いモデル（Qwen）では +9 行、確かなモデル（Mistral）では 0 である。言語化想起は焦点化であり、その逆に Qwen や弱い関係では 0 か負、Mistral では +6 となる。

Qwen3.5 では同じ実演例示が効いている（言語化 96%）のに何も動かない。Mistral の最弱関係 hasCapacity では候補内正解を 60 → 47 に**下げる**。後訓練は効果を完全に切断する：Magistral(Mistral の RL 推論チューニング版) は言語化の形式を 99.9% の遵守率で複写する——thinking チャンネルでも、台本化した thinking チャンネルでも、回答本文でも——のに、アンカー分布は 3 条件のいずれでも動かない（一貫して 70–72）。例示が支配的であることは SFT-instruct モデルの性質であり、RL は応答方針を固定して様式と想起の連動を断つ。

4.5 モデル内の選択に使える情報はないが、系列間の裁定は違う

単一モデルの候補集合内では、少数派の正解値は少数派の誤答値と、測定したすべての特徴（票数・分散・トレース特徴・対数尤度；出現率 8%）で区別できない。判定モデル・信頼度重み・合意

構成要素 (その仕組み)	val	test	再現
実演する例示 (§4.3)	+6	+5	✓
company 表記統合 (§3.2)	+1	+2	✓
8B 裁定 (§4.5)	+2	+1	✓
capacity 最良構成 (6 中)	+2	-2	×
第 2 裁定者 (増分)	+1	0	×
city 2 段生成 × 統合	+11	-1	×

Table 4: 展開した全構成要素の行水準の検証・テスト差分（表 1 の隔離アブレーションより）。分かれ目は効果量ではなく仕組みである：最大の検証利得（+11 行）が最も再現しなかった。

スキームが全滅したのはこのためである。最終的に信号を取り出したのは**様式の異なるプロンプト間の食い違い**である：想起プロンプトと出所指定プロンプトが 5% 超で食い違う約 25 行の上で、系列外の 8B モデルの一票は 3:1 で正解側を裁定する。検証では hasArea 78 → 80(+3/−1; 3 通りのプロンプト対と 2 つの裁定者シードで再現)、hasCapacity 26 → 28(+2/−0)。対照実験が条件を特定する：同様式のプロンプト対は裁定すべき食い違いをほとんど生まない。裁定者のモードで少数クラスを昇格させる方式（2 つの強回答から選ばせるのではなく）は**負**である——8B は 24B のモードを覆せず、二択を裁くことしかできない。弱い裁定者（同系列 Ministral-8B、モード正解 23/100 vs. Llama の 53/100）は hasArea で利得を生まない。公式テストでは、隔離された v3→v4 アブレーション——裁定で変わった capacity 4 行のみ、他は同一——がテストでの再現を確認する：capacity F1 0.204 → 0.214 (+1 行、−0)。

4.6 どの検証上の利得がテストでも再現するか

7 回の提出が構成要素ごとのテスト測定を与える（表 4）。テストでも再現した構成要素はひとつの性質を共有する：その利得に、検証行の統計を参照しない因果的説明があることである——アンカー分布を大域的にシフトする例示様式、集計上の不具合の修復（gold の別名がどちらの表記も受理する票割れ）、行数を減らさない裁定。再現しなかったものは、検分するといずれも検証行の分布への適合である：6 つの capacity 構成からの最良選択（勝者の呪い）、飽和済み裁定者の増分、そして最も教訓的な例として、+11 行の検証利得が「票割れ行の最頻値がたまたま正解である率」という分布的性質に依存していた city パイプライン（テストでは −1 行）。広いしきい値プラトーはこれを防がなかった。100 行の検証セットはこの型の過適合を検出できない

が、仕組みの説明は事前にそれを見分ける。終盤に 2 つの文字列関係へ Wikidata の出所を指定する指示を試した: company 版は検証で正味マイナス、city 版は失敗した統合と同じプロファイル(狭い無回答しきい値のピーク、+9/-4 の入れ替わり)を示し、この分類は再現しないと予測する——我々はこれを展開しなかった。

4.7 残る誤りはコーパス由来の誤った値である

残るものは推論の失敗ではない。Corfu(gold 626 km²) は Mistral 系のすべての instruct 構成で 592.9、Qwen3.5 で 593、Gemma で 580 と回答される——プロンプトを生き延びる、安定したモデル固有の誤値である。3 つの観察がその起源を共有学習コーパスに位置づける。第一に**世代ごとの入れ替わり**: Qwen3.6 は他を変えないまま Qwen3.5 の誤答行 7 行を修復し、新たに 11 行を壊す。世代が解ける行はデータスナップショットとともに入れ替わり、世代をまとめた場合の候補内正解は 89/100 に達する。第二に**系列の異なるモデルが主流の誤答行を解く**: llm-jp-4-32b と Aya Expanse は全体では遥かに弱いのに、主流コーパスのモデルがどれも解けない Corfu をそれぞれ部分的に解く。第三に instruct **チューニングが汚染されたアンカーを増幅する**: 素の続き書きプロンプトの下で Mistral 3.1 Base は診断で「正解あり」10/12・「最頻値」7/12 と自身の instruct 版(9/4)を上回り、すべての instruct 変種が失敗する Borðoy を 20/20 で正答し、Mistral 系で唯一、Corfu の正解値が票の半分を得る構成である。同じ Base 優位は Llama-3.1-8B でも再現する(モード正解 60 vs. 53/100)。Base モデルは特定の誤答行を回復する代わりに全体の焦点を失うため、実用システムは instruct モデルを維持する——しかし観察は残る: closed-book の天井はコーパス共起統計で決まっており、指示チューニングはそれを鋭くする——良くも、汚染された値の上では悪くも。

5 関連研究

言語モデルの事実知識のプロベリングは LAMA (Petroni et al., 2019) に遡る。LM-KBC 系列 (LM-KBC organizers, 2023, 2024) はプロベリングを、基数制約のない KB 構築へ拡張した。self-consistency (Wang et al., 2023) はサンプル回答を多数決で集約し、ReWiSe (Albert-Roulhac and Zouaq, 2025) はそれを関係ごとに調整した。我々の集約は、この系譜を空集合・数値許容誤差・表記ゆれの統合・系列間の裁定へ拡張する。Sprague et al. (2025) は chain-of-thought

が推論には効くが知識想起には効かないと結論する。我々の結果はこれを想起タスクに対して精密化する: 手続きと指示は確かに想起を動かさないが、例示様式は動かす——想起の確かさと後訓練に条件付きで。Ma and Hewitt (2026) は、プロンプティングはパラメトリック知識アクセスを 1-2% しか動かさず RL fine-tuning は ~10% 動かすと報告する。我々が分離した例示効果(対象関係で +6%)はその中間に位置し、fine-tuning という手段は本タスクでは禁止されている。Yuchi et al. (2026) は診断で復元可能な数値知識がモデルの言語化を上回ることを見出し、我々の「候補内正解と最頻値正解の差」のひとつの読みを与える。Kalyan et al. (2021) と Park et al. (2022) は、我々の桁規則・単位併合の対象である桁と単位の脆弱性を記録している。出所指定の指示は「According to...」型の出所手がかり (Weller et al., 2024) の Wikidata 版である。

6 結論

2 プロンプト+裁定者アンサンブルのサンプリングシステム(検証 0.641、テスト 0.625)と、その背後の実験系列を報告した。重要度の順序は: 第一にモデルの想起の確かさ(30 分の診断で測定可能)、第二に例示様式(想起を動かす唯一のプロンプト側の手段であり、その符号条件を我々は明らかにした)、第三に行数を減らさない系列間の裁定、そしてそれ以外——指示・手続き・温度・出力経路・判定モデル・信頼度・合意——は不活性か検証過適合である。7 回の提出にわたるテスト側アブレーションは、val→test で再現するかという問い自体を結果に変えた: 仕組みの説明を持つ利得は再現し、検証行の統計に適合した利得は再現しなかった。本稿の実践的助言は、100 行の検証セットが支持するものを展開する前に、前者を要求せよ、である。

Limitations

仕組みに関する知見は深掘りした 2 つのモデル系列(Qwen、Mistral)に依拠し、生成は多くのプロンプトで単一シードである。シード再現は例示と裁定の結果にのみ存在する。12 行の診断はひとつのシステムの失敗で層化されており、モデル横断の順位は我々が実際に行った展開判断で検証されたものであって、ホールドアウトのモデル集合ではない。100 行関係の候補内正解・最頻値正解の行数は ±1-2 行のノイズを含み、いくつかの負の結果(裁定者の増分など)はその分解能で打ち切られている。Base と Instruct の比較は重みとプロンプト形式(素の

続き書き vs. チャット) を交絡させており、本文で明示した。分離には instruct モデルを素の続き書きで診断する必要があるが、チャットテンプレートがそれを自明でなくしている。残余誤差の汚染説は観察的である——3 つの独立な現象と整合するが、特定のコーパス文書までは遡っていない。集約しきい値は検証で調整されており、4.6 節の再現するかの判別は 1 タスク版・7 提出から導かれ、その予測的使用 (未展開の city プロンプト) は現時点で 1 件の事前登録事例である。展開済みの 2 つの構成要素 (許容誤差ブリッジと素の続き書きによる capacity プロンプト) は複数シード・プロンプト対で検証済みだが、投稿時点で公式 test の測定を持たない。最後に開示として、中間提出 v6-v9 は第 2 の 8B 裁定者によりアンサンブル総パラメータが約 39.8B となり 32B 上限を超過していた。これは自己監査で発見した我々の違反であり、最終構成 (v10) は検証スコア同値のままこれを除去した。v6-v9 の test 値は上限規則の下でリスク付きと読みたい。

References

- Edouard Albert-Roulhac and Amal Zouaq. 2025. [ReWiSe: Relation-wise self-consistency for LLM probing](#). In Joint Proceedings of KBC-LM and LM-KBC @ ISWC 2025, volume 4041 of CEUR Workshop Proceedings.
- Ashwin Kalyan, Abhinav Kumar, Arjun Chandrasekaran, Ashish Sabharwal, and Peter Clark. 2021. How much coffee was consumed during EMNLP 2019? Fermi problems: A new reasoning challenge for AI. In Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP).
- LM-KBC organizers. 2023. Knowledge base construction from pre-trained language models (LM-KBC) 2023: Challenge overview. TODO: verify citation.
- LM-KBC organizers. 2024. Knowledge base construction from pre-trained language models (LM-KBC) 2024: Challenge overview. TODO: verify citation.
- Melody Ma and John Hewitt. 2026. Improving parametric knowledge access in reasoning language models. ArXiv:2602.22193.
- Sungjin Park, Seungwoo Ryu, and Edward Choi. 2022. Do language models understand measurements? In Findings of the Association for Computational Linguistics: EMNLP 2022.
- Fabio Petroni, Tim Rocktäschel, Sebastian Riedel, Patrick Lewis, Anton Bakhtin, Yuxiang Wu, and Alexander Miller. 2019. Language models as knowledge bases? In Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP), pages 2463–2473.
- Zayne Sprague, Fangcong Yin, Juan Diego Rodriguez, Dongwei Jiang, Manya Wadhwa, Prasann Singhal, Xinyu Zhao, Xi Ye, Kyle Mahowald, and Greg Durrett. 2025. To CoT or not to CoT? chain-of-thought helps mainly on math and symbolic reasoning. In The Thirteenth International Conference on Learning Representations (ICLR).
- Xuezhi Wang, Jason Wei, Dale Schuurmans, Quoc Le, Ed Chi, Sharan Narang, Aakanksha Chowdhery, and Denny Zhou. 2023. Self-consistency improves chain of thought reasoning in language models. In The Eleventh International Conference on Learning Representations (ICLR).
- Orion Weller, Marc Marone, Nathaniel Weir, Dawn Lawrie, Daniel Khashabi, and Benjamin Van Durme. 2024. “according to ...”: Prompting language models improves quoting from pre-training data. In Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL).
- Fengting Yuchi, Li Du, and Jason Eisner. 2026. LLMs know more about numbers than they can say. In Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (EACL), Short Papers. ArXiv:2602.07812.

A 再現性

コード・設定・予測ビルダー・手順書 (docs/V4_REPRODUCE.md) ・実験ごとの記録は <https://github.com/acrosasaki-rgb/llm-knowledge-task-2026> で公開する。モデルリビジョン (GGUF リポジトリとコミット) ・コンテナダイジェスト・データセットコミットは固定済みである。最終予測ファイルは保存された 7 つの候補集合とビルダースクリプトの決定的関数であり、再合成はバイト同一に再現する (SHA-256 検証済み)。候補集合はシードを変えても ± 1 行以内で再生成され、100 行 $\times$ 20 候補の生成 1 本は $8 \times A100$ で約 15 分、本稿の比較はすべて凍結した候補集合の CPU 再集約である。